

RELATÓRIO CONSOLIDADO DE ASSESSMENT AI-IS

Assessment AS-IS com IA, sem migrar de plataforma

Determinar se a IA pode reduzir de forma material o esforço manual do levantamento do estado atual dos dados (perfilamento e sugestão de mapeamento) sem aumentar o risco operacional ou de segurança e sem migrar de plataforma. Expectativa inicial de ganho: não definida; o ROI depende de premissas ainda não medidas.

Cada número marcado como medido vem de uma execução reproduzível (make benchmark, make llm-benchmark). O que é premissa ou julgamento aparece marcado como tal.

BASE DE DADOS	MODELO	ESCOPO
5 datasets públicos e sintéticos (exemplo dbt da Cloudera)	deepseek-flash	Perfilamento e sugestão de mapeamento (AS-IS)
GERADO EM	COMMIT	SEÇÕES
2026-09-19 15:49 UTC	3e2ed23	7

RESUMO EXECUTIVO

Resumo executivo: AI-IS sem migração de plataforma

Foi solicitada uma avaliação técnica e econômica para determinar se a IA pode reduzir o esforço manual do assessment AS-IS de dados sem elevar o risco, respeitando uma restrição crítica: **nenhuma linha de dados é enviada ao modelo e nenhuma sugestão é aplicada sem aprovação humana**. Foram executadas 15 chamadas reais a um modelo de linguagem sobre 5 datasets, com 3 repetições cada. A investigação indica **GO CONDICIONAL para um piloto**. A viabilidade técnica está demonstrada (15 de 15 chamadas concluídas, 12 com todas as 6 verificações aprovadas) e o custo do modelo é desprezível (**US\$ 0,000074** por dataset). Porém o **ganho econômico sobre um time de dados e engenharia ainda não está provado**: nenhuma hora humana foi cronometrada.

Principais achados técnicos

- **Viável e barato:** custo total de US\$ 0,0011 para 15 chamadas; 2.724 tokens de entrada e 12.574 de saída, medidos pelo provedor.
- **Velocidade com cauda longa:** mediana de 2,7 s, p95 de 9,7 s e máximo de 11,5 s. O pior caso custou 2,7× a média.
- **Não determinístico:** 4 de 34 colunas mudaram de destino ou tipo entre repetições. Toda sugestão exige aprovação humana.
- **Governança de custo:** cada chamada passa por score, nível, teto de tokens, orçamento e auditoria em livro-razão (Tollgate).
- **Perfilamento determinístico:** 4.771 linhas perfiladas, hash SHA-256 conferido em 4/4 arquivos e 6 de 6 defeitos injetados detectados.

Decisão pedida ao patrocinador

Pede-se a aprovação de duas ações imediatas:

1. **Autorizar o piloto AI-IS** (estimativa de 59 horas, cerca de 2,4 semanas para uma pessoa a 25 h/semana): rodar o AI-IS em 5 datasets reais e cronometrar o assessment manual nos mesmos datasets.
2. **Comprometer os pré-requisitos:** liberar uma amostra de datasets sob acordo de confidencialidade, alocar 1 a 2 analistas para o baseline manual e disponibilizar um ambiente com HTTPS.

Visão geral das seções

SEÇÃO	FONTE DA EVIDÊNCIA	VEREDITO	NÍVEL DE EVIDÊNCIA
Escopo e qualificação	Este repositório	ATENDIDO (escopo AS-IS bem delimitado)	Documental
Resultados medidos	make benchmark, make llm-benchmark	GO (12/15 verificações)	Medido
Análise dos dados	llm.json	ATENÇÃO (instabilidade entre repetições)	Medido
Esforço e capacidade	git, suíte de testes	INFORMATIVO (tempo humano não medido)	Parcial
Economia e ROI	Premissas ilustrativas	NÃO PROVADO	Premissa
Riscos e pré-condições	Análise	GERENCIÁVEL com o piloto	Julgamento

SEÇÃO	FONTE DA EVIDÊNCIA	VEREDITO	NÍVEL DE EVIDÊNCIA
Recomendação	Seções anteriores	GO CONDICIONAL	Julgamento

CONTEÚDO DO RELATÓRIO

01	Escopo e qualificação	O QUE O AI-IS COBRE
02	Resultados medidos	PERFILAMENTO E SUGESTÃO
03	Análise dos dados	DIVERGÊNCIAS E ESTABILIDADE
04	Esforço e capacidade	CONSTRUÇÃO E PILOTO
05	Economia e ROI	TIME VERSUS IA
06	Riscos e pré-condições	O QUE PODE INVALIDAR
07	Recomendação e decisão	PRÓXIMOS PASSOS

Escopo e qualificação


Relatório de qualificação: o que o AI-IS cobre e o que deixa de fora

AI-IS é o assessment do estado atual (AS-IS) dos dados feito com IA e entregue **sem migrar de plataforma**. O valor está em levantar, documentar e sugerir mapeamentos com evidência, sem o custo e o risco de uma migração. A execução da migração fica fora do escopo: depois da aprovação, o Cutover gera o código de carga e de reconciliação, mas nunca o executa.

1. Matriz de aderência e evidência

CRITÉRIO	PESO	RESULTADO	RASTREABILIDADE E EVIDÊNCIA	JUSTIFICATIVA
1. Viabilidade técnica	Alto	Atendido	15/15 chamadas reais; 12 com 6/6 verificações (11m.json)	O fluxo completo funciona ponta a ponta sob portão de custo.
2. Custo de IA	Alto	Atendido	US\$ 0,0011 no total; média de US\$ 0,000074 por dataset	Custo desprezível; o gargalo passa a ser a revisão humana.
3. Reprodutibilidade	Alto	Parcial	30/34 colunas estáveis entre repetições	Sugestões variam; a aprovação humana é obrigatória.
4. Segurança de dados	Alto	Parcial	Payload de teste: só nomes e tipos de colunas; sem linhas de dados	Não testado com dados sensíveis; nomes de coluna também podem ser sensíveis.
5. Dor mensurável	Alto	Não provado	Nenhum baseline manual cronometrado	Sem baseline não há como afirmar o ganho sobre um time.
6. Maturidade do produto	Médio	Parcial	Perfilamento, sugestão, aprovação, relatórios, baseline manual e geração de código disponíveis; código não executado em ambiente real	Cobre o núcleo do assessment, não o entregável final.

2. Fluxo do assessment AI-IS



3. Proposta do piloto

PARÂMETRO	ESPECIFICAÇÃO
Nome	Piloto AI-IS com baseline manual
Duração	Estimativa de 59 horas de trabalho (2,4 semanas para uma pessoa), a validar
Modelo de engajamento	A definir com o patrocinador
Objetivo primário	Medir, em dados reais, o tempo e a qualidade do assessment manual versus AI-IS com revisão humana.

Handoff

CAMPO	VALOR
Nível de evidência	Documental e medido
Bloqueios	Nenhum para o piloto; dados reais dependem de acordo de uso
Próximo passo recomendado	Emitir o escopo do piloto ao patrocinador para aprovação.

Resultados medidos

Perfilamento e sugestão de mapeamento, dataset a dataset

Todos os valores abaixo foram medidos e podem ser refeitos com `make benchmark` (perfilamento) e `make 11m-benchmark` (sugestão com IA). Tokens e custo vêm do provedor; o custo é calculado com os preços informados (US\$ 0,04 de entrada e US\$ 0,08 de saída por milhão de tokens).

1. Sugestão de mapeamento com IA

DATASET	LINHAS	COL.	ALERTAS	LATÊNCIA MEDIANA (S)	MÁX. (S)	CUSTO MÉDIO (US\$)	PARA
raw_covid_cases.csv	510	7	0	6,4	7,1	0,000102	1
raw_covid_vaccines.csv	3.740	10	0	2,7	2,7	0,000042	1
ref_country_codes.csv	255	6	0	2,4	3,1	0,000040	1
ref_populations.csv	266	2	0	1,7	1,8	0,000018	0
raw_covid_cases_with_defects.csv	511	9	7	9,7	11,5	0,000170	1
Total				15 chamadas	11,5	0,000074	0

2. Perfilamento determinístico

ARQUIVO	LINHAS	COLONAS	PERFIL (MS)	UPLOAD ATÉ A PÁGINA (MS)
raw_covid_cases.csv	510	7	7,2	12,6
raw_covid_vaccines.csv	3.740	10	54,6	61,6
ref_country_codes.csv	255	6	3,4	8,8
ref_populations.csv	266	2	1,6	6,3

Medianas de 20 execuções do perfilador e 5 uploads contra um servidor real em localhost. 6 de 6 defeitos injetados de propósito foram detectados, sem alertas falsos em arquivos limpos.

Handoff

CAMPO	VALOR
Nível de evidência	Medido
Bloqueios	Nenhum
Próximo passo recomendado	Repetir as medições com dados reais no piloto.

Análise dos dados

Concordância, divergências, estabilidade e cauda de custo

Esta seção olha além das médias: onde o modelo diverge do perfil, o quanto ele repete a si mesmo e como o pior caso se comporta.

1. Composição dos datasets

DATASET	TIPOS INFERIDOS PELO PERFIL	ALERTAS DO PERFIL
raw_covid_cases.csv	5 integer, 2 text	nenhum
raw_covid_vaccines.csv	6 integer, 4 text	nenhum
ref_country_codes.csv	2 decimal, 1 integer, 3 text	nenhum
ref_populations.csv	1 integer, 1 text	nenhum
raw_covid_cases_with_defects.csv	1 empty, 5 integer, 1 mixed, 2 text	column_names, duplicate_columns, malformed_rows, identical_columns, mixed_types, mostly_empty, duplicate_rows

2. Concordância e divergências com o perfil

Em média 99,1% das colunas receberam um tipo da mesma família que o perfil inferiu. É uma medida de coerência, não de acerto: o perfil também pode estar errado. Dos 6 nomes incompatíveis com Delta apresentados, o modelo corrigiu 6.

DATASET	COLUNA	PERFIL → SUGESTÃO	REPETIÇÕES
raw_covid_cases.csv	date_rep	text → date	1/3

Só um revisor pode dizer se errou o modelo ou o perfil (por exemplo, datas em formato não ISO que o perfil lê como texto). Cada divergência é um ponto de revisão humana.

3. Estabilidade entre repetições

30 de 34 colunas (88%) receberam o mesmo destino e tipo nas 3 repetições.

INSTABILIDADE ENTRE REPETIÇÕES

4 colunas mudaram de destino ou tipo entre repetições do mesmo dataset. Trate a sugestão como rascunho, não como resultado reproduzível.

4. O que as verificações determinísticas pegaram

Em 3 de 15 chamadas, o modelo sugeriu algo que uma verificação calculada rejeitou. Um modelo que revisasse o próprio trabalho não teria como saber.

DATASET	VERIFICAÇÃO	REPETIÇÕES	EXEMPLO DO QUE FOI REJEITADO
ref_populations.csv	type_fits_data	3/3	population: int, valores até 7761620146 não cabem em int (use bigint)

Sem a checagem contra os dados medidos, essas sugestões teriam seguido para revisão como se estivessem corretas.

5. Cauda de latência e de custo

MÉTRICA	VALOR	LEITURA
Latência mediana	2,7 s	Tempo típico de uma sugestão.
Latência p95	9,7 s	1 em 20 chamadas leva ao menos isto.
Latência máxima	11,5 s	O modelo raciocina antes de responder; o tempo varia.
Custo médio	US\$ 0,000074	Por sugestão.
Custo máximo	US\$ 0,000201	2,7× a média; o teto de saída do portão limita o pior caso.

Handoff

CAMPO	VALOR
Nível de evidência	Medido
Bloqueios	Nenhum; a instabilidade exige o gabarito humano do piloto
Próximo passo recomendado	Coletar as decisões dos revisores para medir a taxa de aceite sem edição.

Esforço e capacidade

O que foi entregue e o que o piloto exige

1. Esforço de construção (medido)

PARÂMETRO	VALOR	FONTE
Commits desde o rebranding	30	git
Arquivos alterados	130	git
Linhas de código (SDK, app, front-end)	7.582	git, contagem de linhas
Testes automatizados	88	pytest
Intervalo entre o primeiro e o último commit	2,3 h	git (2026-09-19 10:50 a 2026-09-19 13:10)

Por que não comparamos com o esforço de um time. O intervalo entre commits é o único registro de tempo, e ele não inclui a revisão e a direção humanas. Sem uma medição do tempo humano no ciclo, qualquer comparação seria estimativa, então ela não é feita aqui.

2. Esforço estimado do piloto (ilustrativo)

Estimativas de três pontos, com $E = (O + 4M + P) / 6$. São premissas a validar com o cliente, não medições.

CÓDIGO	TAREFA	O (H)	M (H)	P (H)	E (H)	RASTREABILIDADE
1.1	Curadoria da amostra de datasets e acordo de uso dos dados (NDA)	6,0	10,0	20,0	11,0	Pré-condição de dados reais
1.2	Cronometrar o assessment manual em 5 datasets (baseline)	8,0	12,0	20,0	12,7	Fecha a lacuna do ROI
1.3	Rodar o AI-IS nos mesmos datasets e registrar a revisão humana	6,0	10,0	18,0	10,7	Mesmos 5 datasets do baseline
1.4	Análise de qualidade com revisores (aceite sem edição, divergências)	8,0	14,0	24,0	14,7	Cria o gabarito humano
1.5	Relatório final de decisão com ROI medido	6,0	10,0	16,0	10,3	Substitui as premissas por medições
Total	Piloto AI-IS	34,0	56,0	98,0	59,3	2,4 semanas a 25 h/semana

ESTIMATIVA NÃO VERIFICADA

As horas do piloto são estimativas ilustrativas. Valide-as com quem executará o trabalho antes de assumir prazo ou custo.

Handoff

CAMPO	VALOR
Nível de evidência	Parcial (construção medida; piloto estimado)
Bloqueios	Nenhum
Próximo passo recomendado	Validar a estimativa do piloto com o time que executará.

Economia e ROI

Assessment feito por um time versus IA com revisão humana

O cálculo compara o custo de um assessment feito à mão com o custo da IA mais a revisão humana. **Não inclui custo nem risco de migração**, porque o AI-IS entrega o resultado sem migrar de plataforma.

PREMISSAS NÃO VERIFICADAS

Todos os parâmetros abaixo são premissas ilustrativas, exceto o custo de IA por dataset, que vem da medição. Na versão online, edite os valores e o resultado se recalcula. O resultado só vale com os seus números.

1. Parâmetros

PARÂMETRO	VALOR	ORIGEM
Datasets por assessment	50	Premissa ilustrativa
Assessments por ano	4	Premissa ilustrativa
Horas do time por dataset, à mão (h)	2,0	Premissa ilustrativa
Horas de revisão humana por dataset, com IA (h)	0,25	Premissa ilustrativa
Custo horário do time (carga total) (US\$/h)	60,0	Premissa ilustrativa
Custo de plataforma por assessment (US\$)	50,0	Premissa ilustrativa
Esforço único de adoção (h)	40,0	Premissa ilustrativa
Custo de IA por dataset (US\$)	0,000074	Medido (11m.json)

2. Resultado

INDICADOR	VALOR
Custo de um assessment, à mão	US\$ 6.000
Custo de um assessment, com IA e revisão	US\$ 800
Economia por assessment	US\$ 5.200
Horas devolvidas ao time por assessment	88 h
Redução de custo	87%
Economia anual	US\$ 20.800
Payback (em assessments)	0,5
ROI no primeiro ano	767%

3. Sensibilidade do ROI no primeiro ano

	0,10 H	0,25 H	0,50 H	1,00 H
0,5 h à mão	92%	17%	-108%	-358%
1,0 h à mão	342%	267%	142%	-108%
2,0 h à mão	842%	767%	642%	392%
4,0 h à mão	1.842%	1.767%	1.642%	1.392%
8,0 h à mão	3.842%	3.767%	3.642%	3.392%

Linhas: horas do time por dataset, à mão. Colunas: horas de revisão por dataset, com IA. O gargalo econômico é a revisão humana, não o custo do modelo, que é de frações de centavo por dataset.

Handoff

CAMPO	VALOR
Nível de evidência	Premissa (só o custo de IA é medido)
Bloqueios	Baseline manual não medido
Próximo passo recomendado	Cronometrar o assessment manual em 5 datasets e refazer este cálculo.

Riscos e pré-condições

O que pode invalidar esta leitura

1. Riscos principais

ÁREA DE RISCO	SEVERIDADE	CAUSA RAIZ E CONTEXTO	MITIGAÇÃO OU PRÉ-CONDIÇÃO EXIGIDA
Baseline manual não medido	Alta	Nenhuma hora de time humano foi cronometrada; o ROI depende das premissas.	Cronometrar 5 datasets à mão no piloto.
Amostra pequena e sintética	Alta	5 datasets, 15 chamadas, 1 modelo, 1 máquina; sem dados sensíveis.	Repetir com dados reais de um cliente.
Qualidade sem gabarito humano	Média	A checagem mede regras (nomes, tipos, colisões), não se o mapeamento é o que o negócio quer.	Medir a taxa de aceite sem edição pelos revisores.
Instabilidade e cauda de latência	Média	4 colunas instáveis; máximo de 11,5 s por chamada.	Aprovação humana obrigatória; limite de tempo por chamada.
Privacidade de nomes de coluna	Média	Só nomes e tipos vão ao modelo, mas nomes podem revelar informação de negócio.	Acordo de uso de dados e revisão de segurança antes do piloto.
Preço do modelo por confirmar	Baixa	Os preços vieram de um cartão de modelo; a API expõe deepseek-flash.	Confirmar os preços do modelo em uso.
Score heurístico	Baixa	O score que escolhe o nível é provisório (36 + 2 por coluna + 4 por alerta).	Calibrar com dados do piloto.

Handoff

CAMPO	VALOR
Nível de evidência	Julgamento
Bloqueios	Acordo de uso de dados para o piloto
Próximo passo recomendado	Fechar o acordo de dados e a revisão de segurança.

Recomendação e decisão

Três caminhos, com critérios para decidir

1. Opções

OPÇÃO	QUANDO FAZ SENTIDO	O QUE FALTA
Piloto AI-IS (recomendado)	Há um cliente com dados reais e disposição de medir o baseline manual em paralelo.	Acordo de dados, ambiente com HTTPS, cronometragem de 5 datasets à mão.
Ampliar a cobertura antes	O risco for a qualidade em outras origens (Oracle, Snowflake, SAP).	Conectores de origem e mais fixtures.
Não prosseguir	O ganho de horas não justificar a revisão humana.	Rodar o cálculo da seção 05 com os números do seu time.

2. Critérios de sucesso propostos para o piloto

A calibrar com o cliente:

- 1. **Baseline medido** em 5 datasets, com o tempo humano cronometrado.
- 2. **Taxa de sugestões aceitas sem edição** pelos revisores, definida antes do início.
- 3. **Custo de IA por dataset** abaixo do custo de 1 hora do time.
- 4. **Tempo de revisão por dataset** abaixo do baseline manual.
- 5. **Zero linhas de dados** enviadas ao modelo.

3. Decisão pedida

Autorizar o piloto AI-IS e comprometer os pré-requisitos descritos no resumo executivo. A decisão de investir continua sendo do patrocinador; este relatório separa o que foi medido do que foi assumido para que ela seja tomada com esse critério.

Handoff

CAMPO	VALOR
Nível de evidência	Julgamento apoiado em medições
Bloqueios	Nenhum além dos pré-requisitos do piloto
Próximo passo recomendado	Emitir o escopo do piloto ao patrocinador para aprovação comercial.